


Lab Assignment

Data Quality & Data Cleaning

การเตรียมข้อมูลร้านค้าออนไลน์ก่อนโหลดเข้าสู่ Data Warehouse ด้วย Python (Pandas)



รายวิชา	
ชื่อ-นามสกุล	
รหัสนิสิต	
วันที่ส่ง	

1. สถานการณ์จำลอง

ทีม Data Warehouse ได้รับไฟล์ธุรกรรมจากระบบร้านค้าออนไลน์หลายแหล่ง แต่ยังไม่สามารถโหลดเข้าคลังข้อมูลได้ทันที เนื่องจากพบค่าว่าง รูปแบบวันที่ไม่ตรงกัน ข้อมูลซ้ำ ค่าที่ไม่ผ่านกฎธุรกิจ ยอดเงินผิดปกติ และการโหลดข้อมูลล่าช้า นิติกรรับบทเป็น Data Engineer ที่ต้องสร้าง Data Refinery เพื่อสำรวจ ทำความสะอาด และจัดทำหลักฐานว่าคุณภาพข้อมูลดีขึ้นอย่างไร

ข้อกำหนดสำคัญ: ห้ามลบหรือแก้ไข Outlier โดยอัตโนมัติโดยไม่พิจารณา Is_Promotion และ Business Context

2. ผลลัพธ์การเรียนรู้

1. ทำ Data Profiling ด้วย df.info(), isnull(), describe() และ duplicated()
2. ระบุปัญหาโดยอ้างอิง 6 มิติของ Data Quality
3. จัดการ Missing Values โดยรักษาจำนวน Fact rows และสร้าง Flag เพื่อให้ตรวจสอบย้อนหลังได้
4. จัดรูปแบบข้อมูลให้สอดคล้อง เช่น Gender, Payment Method และ Order Date
5. ตรวจสอบ Accuracy/Validity ด้วย Business Rules และตรวจสอบ Outlier ด้วย IQR
6. สร้าง Clean Dataset และ Data Quality Report ที่พร้อมนำไปต่อยอดใน Data Pipeline

3. Dataset และคอลัมน์สำคัญ

คอลัมน์	ความหมาย	ปัญหาที่อาจพบ
Transaction_ID	รหัสธุรกรรม	ข้อมูลซ้ำ / คีย์ไม่เป็นเอกลักษณ์
Customer_ID	รหัสลูกค้า	ใช้สร้าง Unknown member และตรวจสอบ Near Duplicate
Customer_Email	อีเมลลูกค้า	Missing Values / Secondary Unique Key
Gender	เพศ	M, Male, male, m, F, Female ฯลฯ
Order_Date	วันที่สั่งซื้อ	YYYY-MM-DD, DD/MM/YYYY, MM/DD/YYYY และค่าที่ไม่ใช่วันที่

Load_Timestamp	เวลาที่ข้อมูลเข้าระบบ	ใช้ประเมิน Timeliness และช่วยแก้ความกำกวมของวันที่
Quantity, Unit_Price, Discount_Rate	ส่วนประกอบยอดขาย	ค่าที่ไม่ผ่านกฎธุรกิจ
Transaction_Amount	ยอดสุทธิ	ไม่ตรงสูตร / Outlier / ค่าติดลบ
Is_Promotion	รายการโปรโมชั่น	Outlier ที่อาจเป็นธุรกรรมจริงและมีคุณค่าทางธุรกิจ

4. 6 มิติของคุณภาพข้อมูลที่ใช้ใน Lab

มิติ	คำถามตรวจสอบใน Lab
Accuracy	ยอด Transaction_Amount ตรงกับ $\text{Quantity} \times \text{Unit_Price} \times (1 - \text{Discount_Rate})$ หรือไม่
Completeness	Customer_Email และ Province ครบหรือไม่
Consistency	วันที่ เพศ วิธีชำระเงิน และสถานะใช้รูปแบบเดียวกันหรือไม่
Uniqueness	มี Exact Duplicate หรือ Customer เดียวกันแต่ชื่อเขียนต่างกันหรือไม่
Timeliness	ข้อมูลเข้าสู่ Warehouse ภายใน 24 ชั่วโมงหรือไม่
Validity	Quantity, Status, Keys และ Amount ผ่าน Business Rules หรือไม่

ขั้นตอนปฏิบัติ

Task 1 — Data Profiling (15 คะแนน)

- แสดงจำนวนแถว/คอลัมน์ ชนิดข้อมูล และตัวอย่างอย่างน้อย 5 แถว
- สรุป Missing Values รายคอลัมน์ จำนวน Exact Duplicates และสถิติของตัวแปรตัวเลข
- ระบุปัญหาอย่างน้อย 5 ปัญหา และจับคู่กับ Data Quality อย่างน้อย 3 มิติ

```
df.info()
df.isnull().sum()
df.describe(include='all').T
df.duplicated().sum()
```

Task 2 — Completeness (15 คะแนน)

- สร้าง Customer_Email_Was_Missing และ Province_Was_Missing ก่อนแก้ไขข้อมูล
- ห้าม drop แถวเพียงเพราะ Customer_Email หาย เพราะจะทำให้ Fact และยอดขายสูญหาย
- เติมอีเมลแบบ traceable เช่น unknown_<Customer_ID>@unknown.local และเติม Province เป็น Unknown
- อธิบายเหตุผลว่าทำไม mean imputation ใช้กับอีเมลไม่ได้

Task 3 — Consistency (20 คะแนน)

- แปลง Gender ให้เหลือ M, F, Unknown
- แปลง Payment_Method ให้เหลือ Credit Card, PromptPay, Cash on Delivery, Bank Transfer, Unknown
- แปลง Order_Date ให้เป็น YYYY-MM-DD และสร้าง Order_Date_Parse_Method
- ใช้ Load_Timestamp ช่วยตัดสินใจวันที่กำกวมระหว่าง DD/MM/YYYY และ MM/DD/YYYY
- ค่าที่ไม่สามารถอ่านได้อาจ fallback เป็นวันที่จาก Load_Timestamp แต่ต้องสร้าง Order_Date_Was_Imputed

Task 4 — Uniqueness (10 คะแนน)

- นับและลบ Exact Duplicate ด้วย drop_duplicates(keep="first")
- ค้นหา Near Duplicate โดยพิจารณา Secondary Key เช่น Customer_Email หรือ Customer_ID
- อธิบายข้อจำกัดของ Exact Match และแนวทาง Fuzzy Matching ในระบบจริง

Task 5 — Accuracy และ Validity (15 คะแนน)

- ตรวจสอบ Quantity ให้อยู่ในช่วง 1–20 และสร้าง Quantity_Was_Invalid
- คำนวณ Expected_Amount และสร้าง Accuracy_Flag เมื่อผลต่างมากกว่า 1 บาท
- Standardize Order_Status และตรวจค่าที่ไม่อยู่ในชุด Completed, Processing, Cancelled, Returned
- ไม่แก้ยอดของรายการโปรโมชั่นอัตโนมัติ ให้เก็บไว้ตรวจสอบด้วย Business Context

```
Expected_Amount = Quantity * Unit_Price * (1 - Discount_Rate)
```

Task 6 — Outliers ด้วย IQR และ Capping (15 คะแนน)

- คำนวณ Q1, Q3 และ IQR จากรายการที่ Is_Promotion != Y
- สร้าง Lower Bound = $Q1 - 1.5 \times IQR$ และ Upper Bound = $Q3 + 1.5 \times IQR$
- สร้าง Outlier_Flag_Before_Capping ก่อนแก้ค่า
- ทำ Capping ด้วย clip() เฉพาะรายการที่ไม่ใช่โปรโมชั่น
- แสดง Boxplot ก่อนและหลังทำความสะอาด

```
Q1 = s.quantile(0.25)
Q3 = s.quantile(0.75)
IQR = Q3 - Q1
lower = Q1 - 1.5 * IQR
upper = Q3 + 1.5 * IQR
```

Task 7 — Timeliness, Report และ Export (10 คะแนน)

- คำนวณ Load_Delay_Hours และกำหนด Late เมื่อมากกว่า 24 ชั่วโมง
- สร้าง Data Quality Report ก่อน-หลังอย่างน้อย 8 ตัวชี้วัด
- Export ไฟล์ e_commerce_clean.csv และ data_quality_report.csv ด้วย UTF-8-SIG

6. คำถามวิเคราะห์

7. การ drop แถวที่ Customer_Email หายส่งผลต่อยอดขายรวมอย่างไร?
8. ยกตัวอย่างวันที่กำหนดและอธิบายหลักฐานที่ใช้แปลงวันที่
9. เหตุใด drop_duplicates() จึงไม่พบ Thomas และ Tom ว่าอาจเป็นคนเดียวกัน?

10. ยอดที่ไม่ตรงสูตรควรถูกแก้ทุกแถวหรือไม่? Is_Promotion เปลี่ยนการตัดสินใจอย่างไร?
11. เหตุใด Outlier ตาม IQR จึงอาจเป็น Insight ที่มีค่าทางธุรกิจ?

7. Deliverables

ไฟล์	ชื่อที่แนะนำ	สิ่งที่ต้องมี
Notbook หรือ Sourcecode	<รหัสனிสิต>_data_quality_lab.ipynb	รันจากบนลงล่างได้ มีผลลัพธ์ ตาราง กราฟ และคำตอบ
Clean Data	e_commerce_clean.csv	ไม่มี Exact Duplicate, อีเมลไม่เป็น Null, วันที่มาตรฐาน และมี Quality Flags
Quality Report	data_quality_report.csv	ตัวชี้วัดก่อน-หลังอย่างน้อย 8 รายการ

ข้อกำหนดสำคัญ: ส่งเป็น Github Repository